


Projet Computer Vision — IG.2405 (2026)

Lecture automatique de formulaires d'examens semi-structurés

Société DeepForm — validation des présences et lecture automatisée des formulaires

Analyse automatique des formulaires — schéma fonctionnel



Équipe : [Noms et prénoms à compléter]

Module IG.2405 — Vision par ordinateur — ISEP

Juin 2026

Table des matières

Résumé.....	3
1. Position du problème.....	3
2. État de l'art.....	4
3. Description des méthodes.....	4
3.1. Architecture générale et schéma fonctionnel.....	4
3.2. Prétraitement et normalisation géométrique.....	5
3.3. Lecture des éléments graphiques (méthodes de bas niveau).....	6
3.4. Authentification des signatures.....	8
3.5. Reconnaissance du texte manuscrit (réseaux de neurones).....	9
3.6. Reconnaissance du texte imprimé.....	10
3.7. Paramètres du système.....	11
4. Protocole expérimental.....	11
5. Résultats expérimentaux et discussion.....	11
6. Conclusion et perspectives.....	13
Références.....	13

Résumé

Ce rapport présente un système de vision par ordinateur conçu pour la correction automatique de formulaires d'examens semi-structurés pour la société DeepForm. À partir des photos de première page (validation des présences) et des formulaires numérisés au format PDF (lecture complète), le système authentifie les signatures, identifie l'étudiant, lit les informations imprimées, graphiques et manuscrites, et produit des fichiers tableurs structurés conformes au cahier des charges. Conformément aux consignes, les **éléments graphiques** (grilles d'identifiant, cases à cocher, cryptogrammes) sont traités par des **méthodes de bas niveau** — seuillage d'Otsu, morphologie mathématique, transformée de Hough, analyse de composantes connexes, corrélation croisée normalisée — sans aucun détecteur de haut niveau prêt à l'emploi. Les **textes** imprimés et manuscrits sont confiés à des **méthodes de plus haut niveau** : reconnaissance optique de caractères (easyOCR) pour l'imprimé, et réseaux de neurones convolutifs (CNN) entraînés sur EMNIST puis affinés sur les données du projet pour le manuscrit. L'authentification des signatures repose sur une combinaison de descripteurs complémentaires (HOG, moments de Hu, corrélation de gabarit).

Le pipeline complet s'exécute de bout en bout, sans aucune intervention manuelle et sans plantage, ce qui le rend éligible au challenge. Sur le formulaire FORM1, il atteint une exactitude globale de **63,2 % par cellule**, avec des performances contrastées selon la nature de l'information (imprimé 83,6 %, graphique 61,5 %, signature 58,5 %, manuscrit 22,9 %) ; la lecture du Student ID sur les grilles atteint **84 à 100 %** selon les sous-bases. Une analyse critique met en évidence les facteurs limitants — difficulté intrinsèque de la reconnaissance d'écriture, faible volume de données annotées, sensibilité de la segmentation, et une erreur dans la vérité terrain fournie — et propose des perspectives d'amélioration chiffrées.

1. Position du problème

La société DeepForm développe un outil de lecture automatique de formulaires d'examens **semi-structurés**. « Semi-structuré » signifie que le document combine des éléments bien définis (en-têtes, grilles, cases à cocher) avec une mise en page variable et des champs renseignés à la main (chiffres, lettres, signatures). Énoncés et zones de réponse cohabitent dans un même document ; il n'existe pas de grille de réponse indépendante, ce qui interdit les solutions classiques de lecture de QCM sur formulaire dédié.

Le scénario comporte deux flux de données. D'une part, chaque étudiant photographie la première page d'identification de son sujet et la dépose en ligne : l'ensemble des photos constitue le répertoire des présences. D'autre part, le professeur numérise les copies papier en un fichier PDF par formulaire. Le système doit alors remplir trois objectifs : (1) valider les présences et authentifier les signatures à partir des photos ; (2) authentifier chaque formulaire scanné et le lire automatiquement ; (3) attribuer une note (programme de fusion, hors périmètre). Le présent travail implémente les **Programmes 1 et 2** du cahier des charges. Le Programme 1 (*autoValidPresences*) produit un fichier de présences à trois colonnes — nom de l'image, identifiant lu sur la grille, identifiant déduit de la signature. Le Programme 2 (*autoReadForm*) génère, pour chaque PDF, un classeur à deux onglets : *PAGE-01* (identité, conditions d'examen, notes, validation de signature et de cryptogramme) et *EXAM* (réponses : choix multiples, mantisse, exposant, unité).

Contraintes méthodologiques. Le cahier des charges impose une séparation stricte des moyens. Les éléments graphiques doivent être traités **exclusivement** par des fonctions de bas niveau (filtrage, morphologie, Hough, rotation, composantes connexes) ; l'usage de détecteurs de haut niveau prêts à

l'emploi (détection automatique de rectangles ou de cases cochées) est proscrit. À l'inverse, les textes imprimés ou manuscrits peuvent être traités par des méthodes de plus haut niveau, notamment des réseaux de neurones, sous réserve de **justifier les choix, les paramètres et les architectures**. Cette contrainte structure l'ensemble de notre conception : chaque étage du pipeline est explicitement rattaché à l'une ou l'autre catégorie.

Difficultés. Le problème cumule plusieurs difficultés classiques de la vision par ordinateur : géométrie variable des photos prises à main levée (rotation, perspective, ombres), faible contraste de certaines encres, grande diversité des écritures manuscrites, ressemblance possible entre signatures, et — annoncées pour le challenge — des usurpations d'identité, des échanges de pages et de fausses signatures. Le système doit donc être à la fois robuste géométriquement et discriminant.

2. État de l'art

L'analyse automatique de documents structurés constitue un domaine établi de la vision par ordinateur et de la reconnaissance de formes [1]. Le traitement d'un formulaire se décompose classiquement en trois étapes : prétraitement et normalisation géométrique, segmentation des zones d'intérêt, puis reconnaissance des contenus. Notre architecture suit fidèlement ce découpage.

La **normalisation** d'images acquises à main levée s'appuie couramment sur la mise en correspondance de points caractéristiques entre l'image et un gabarit de référence. Les détecteurs SIFT [2] et ORB [3], associés à l'estimation d'une homographie robuste par RANSAC [4], permettent de recalibrer une photographie déformée dans un repère canonique. Le redressement d'inclinaison (*deskew*) repose fréquemment sur la transformée de Hough [5] appliquée aux contours. La **lecture de cases à cocher** relève de la reconnaissance optique de marques (*Optical Mark Recognition*) ; les approches de bas niveau exploitent le taux de remplissage (densité d'encre) et la morphologie de la marque [6].

La **reconnaissance de caractères manuscrits** a été popularisée par les bases MNIST et EMNIST [7] et par les réseaux convolutifs, dont l'architecture fondatrice LeNet-5 [8] ; l'**apprentissage par transfert** permet d'adapter un réseau pré-entraîné à un domaine cible disposant de peu d'exemples [9]. La reconnaissance de **texte imprimé** est aujourd'hui assurée par des architectures convolutives-récurrentes (CRNN) intégrées dans des bibliothèques open-source telles qu'easyOCR. Enfin, la **vérification de signatures hors-ligne** combine des descripteurs de forme et de texture — histogrammes de gradients orientés (HOG) [10], moments invariants de Hu [11] — et des mesures de similarité par corrélation de gabarit. Nous reprenons ces briques éprouvées en les adaptant et en les combinant aux contraintes du sujet.

3. Description des méthodes

3.1. Architecture générale et schéma fonctionnel

Le système est organisé de façon **modulaire** autour d'un programme principal (*main*) qui définit le nom de l'examen et le répertoire des signatures, en déduit les répertoires d'entrée et de sortie, crée le répertoire de résultats, puis exécute successivement les deux programmes. Chaque programme appelle une sous-fonction par document — *autoValidID* pour une photo, *autoReadFormID* pour un PDF — conformément aux signatures imposées au §3 du cahier des charges. Ce découpage n'est pas qu'esthétique : il garantit que l'adaptation au challenge se limite à quelques lignes du *main* (noms de répertoires), le cœur du traitement restant inchangé. La Figure 1 résume le flux de traitement, des entrées jusqu'aux fichiers produits, en distinguant les trois étages (prétraitement, segmentation,

reconnaissance) et la nature des méthodes employées (bas niveau pour le graphique, haut niveau pour le texte).

Analyse automatique des formulaires — schéma fonctionnel




Figure 1 — Schéma fonctionnel du système : prétraitement, segmentation et reconnaissance, puis génération des fichiers de résultats par les Programmes 1 et 2.

3.2. Prétraitement et normalisation géométrique

Toutes les lectures s'effectuent dans un **repère canonique** de dimensions fixes $W \times H = 900 \times 1270$ pixels, dans lequel les régions d'intérêt (ROI) de chaque champ sont calibrées une fois pour toutes. Ce choix est central : en ramenant tout document dans un repère commun, on rend les positions des champs stables et on évite de redétecter chaque zone, ce qui serait à la fois coûteux et fragile. Les dimensions 900×1270 reproduisent le rapport d'aspect A4 à une résolution suffisante pour lire les grilles sans alourdir les calculs.

Formulaires PDF. Chaque page est rendue en image à 150 points par pouce (compromis entre lisibilité des petits caractères et coût mémoire), puis ramenée au repère canonique. Les pages étant des numérisations propres, un simple recadrage de la zone active suivi d'un redimensionnement suffit, complété si nécessaire d'un redressement d'inclinaison.

Photographies. Les photos, prises à main levée, subissent rotation, perspective et ombrage : un recadrage par boîte englobante ne suffit pas pour qu'un ROI fixe tombe sur la bonne grille. On les recalcule donc sur un **gabarit de référence** (l'image normalisée d'une première page) par mise en correspondance de points. Des points caractéristiques sont extraits par **ORB** sur le gabarit et sur la photo, appariés au plus proche voisin avec le **test de ratio de Lowe** (seuil 0,75), puis une homographie H est estimée de façon robuste par **RANSAC**. La photo est enfin projetée dans le repère canonique :

$$\mathbf{x}' \simeq \mathbf{H} \mathbf{x}, \quad \mathbf{H} \in \mathbb{R}^{3 \times 3}$$

Justification du choix d'ORB. Nous avons préféré ORB à SIFT pour trois raisons : il est libre de droits (SIFT a longtemps été breveté), son descripteur binaire se compare par distance de Hamming, très rapide, et il fournit largement assez d'appariements sur nos formulaires riches en texte (plusieurs

centaines de correspondances valides en pratique, cf. Figure 2). Le gabarit étant **identique** pour tous les étudiants, un seul template figé suffit ; nous le livrons avec le projet pour garantir un recalage déterministe, indépendant du PDF présent dans le répertoire. Un chemin de repli détecte les quatre marques de coin en « L » par corrélation de gabarits synthétiques multi-échelles puis applique une transformation perspective ; si tout échoue, on retombe sur un *deskew* par transformée de Hough qui estime l'angle dominant θ par la médiane des orientations proches de l'horizontale, puis applique une rotation de $-\theta$:

$$\theta = \text{median} \{ \alpha_i - 90^\circ : |\alpha_i - 90^\circ| < 45^\circ \}$$

Pretraitement - recalage d'une photo sur le gabarit de reference




Figure 2 — Recalage d'une photo prise à main levée : appariements ORB entre le gabarit et la photo, puis projection par homographie (RANSAC) dans le repère canonique 900×1270.

3.3. Lecture des éléments graphiques (méthodes de bas niveau)

Le socle commun est la **binarisation** d'une ROI par seuillage d'Otsu (inverse), produisant une image I_b où l'encre vaut 1. Le seuillage d'Otsu est choisi parce qu'il s'adapte automatiquement au contraste local de chaque ROI, sans paramètre à régler. Le **taux d'encre** d'une région R est défini par :

$$\rho(R) = \frac{1}{|R|} \sum_{p \in R} 1[I_b(p) = 1] \in [0, 1]$$

Identifiant étudiant et groupe (grilles). L'identifiant et le groupe sont inscrits dans des grilles graphiques : pour chaque position, l'étudiant marque, dans une colonne, la ligne correspondant au chiffre (0–9) ou à la lettre. Chaque colonne c est binarisée globalement puis découpée en R cellules ; le symbole retenu est la ligne de taux d'encre maximal, acceptée si le pic dépasse un seuil τ_{grille} ($= 0,04$) :

$$d_c = \arg \max_{r \in \{0, \dots, R-1\}} \rho(C_{c,r}), \quad \rho(C_{c,d_c}) > \tau_{\text{grille}}$$

Justification. La règle « une marque par colonne » transforme la lecture en un simple *arg max* du taux d'encre, très robuste : elle ne dépend pas de la forme exacte de la coche (croix, point, remplissage) mais seulement de la position de la cellule la plus encrée. Le seuil d'acceptation est volontairement **bas** (0,04) car les colonnes contiennent toujours une marque ; il sert uniquement à rejeter une colonne vide ou illisible. La Figure 3 montre la carte des taux d'encre et la sélection par colonne aboutissant à l'identifiant correct.




Figure 3 — Décodage de la grille Student ID : ROI extraite, binarisation d'Otsu, puis carte des taux d'encre ρ par cellule ; l'arg max par colonne reconstitue l'identifiant 19283.

Cases à cocher (conditions d'examen, choix multiples). Après binarisation et suppression d'une marge interne (pour exclure la bordure de la case), une case est jugée cochée si son taux d'encre dépasse un seuil τ_{encre} **et** qu'elle présente soit une croix, soit un remplissage dense :

$$\rho(\text{int}) \geq \tau_{\text{encre}} \quad \wedge \quad (\text{motifX} \vee \rho(\text{int}) > 0.30)$$

La détection du **motif en croix** érode légèrement la région (suppression des bords) puis mesure la densité d'encre le long des deux diagonales ; une croix est reconnue si les deux diagonales sont suffisamment marquées :

$$\text{motifX} \Leftrightarrow \rho_{d^+} > \tau_{\text{diag}} \quad \wedge \quad \rho_{d^-} > \tau_{\text{diag}}$$

Justification. Combiner densité et motif diagonal évite deux écueils symétriques : une case faiblement cochée mais clairement croisée est acceptée (grâce au motif), tandis qu'une simple salissure diffuse est rejetée (faute de structure diagonale). Les carrés pleins (réponse « OUI » des conditions) sont, eux, détectés par un seuil de remplissage plus élevé (0,35). La Figure 4 illustre les projections diagonales sur une case cochée.




Figure 4 — Détection bas niveau d'une case cochée : la case est binarisée, sa bordure retirée, puis les deux projections diagonales (densités ρ) confirment la présence d'un motif en croix.

Cryptogramme. Un petit motif graphique en pied de page doit être identique sur toutes les pages. On compare le cryptogramme de la page 1 à celui de chaque page par **corrélation croisée normalisée** (NCC) de leurs versions binaires recadrées à taille fixe :

$$\text{NCC}(a, b) = \frac{\sum (a - \bar{a})(b - \bar{b})}{\sqrt{\sum (a - \bar{a})^2 \sum (b - \bar{b})^2}} \in [-1, 1]$$

Le cryptogramme est validé si une **majorité** des pages exploitables vérifie $\text{NCC} \geq 0,50$, les pages où le motif est absent à cette position étant ignorées. Ce vote majoritaire, plutôt qu'une exigence d'identité parfaite sur toutes les pages, rend la vérification robuste aux légers décalages de numérisation (Figure 5).

Vérification du cryptogramme par corrélation normalisée (NCC) + vote majoritaire




Figure 5 — Vérification du cryptogramme : le motif de la page 1 et celui d'une page d'examen sont binarisés à taille fixe ; leur NCC élevée confirme l'identité, le verdict final reposant sur un vote majoritaire.

3.4. Authentification des signatures

La signature est extraite de l'intérieur de sa boîte (hors label et cadre) puis **normalisée** : binarisation d'Otsu, suppression des composantes assimilables au cadre, recadrage sur la boîte englobante de l'encre avec marge, redimensionnement à ratio préservé vers un canevas fixe de 192×96 pixels, et recentrage sur le centre de masse afin de réduire la sensibilité à un décalage du tracé. Le format paysage 192×96 respecte le rapport d'aspect typique d'une signature ; le recentrage par centre de masse — plutôt qu'un simple centrage géométrique — aligne les tracés indépendamment de leur position dans la boîte.

Trois descripteurs **complémentaires** sont calculés sur l'image normalisée : un histogramme de gradients orientés (HOG, 9 orientations, cellules 16×16, blocs 2×2, normalisation L2-Hys), le vecteur des sept moments de Hu (invariants à la translation, à l'échelle et à la rotation), et l'image binaire elle-même servant de gabarit. La similarité entre une signature requête q et une référence p combine la corrélation de gabarit et les similarités cosinus des descripteurs :

$$s(q, p) = w_1 \text{NCC}(q, p) + w_2 \cos(h_q, h_p) + w_3 \cos(u_q, u_p)$$

avec la similarité cosinus définie par :

$$\cos(a, b) = \frac{\langle a, b \rangle}{\|a\| \|b\|}$$

Justification des poids (0,60 ; 0,35 ; 0,05). La corrélation de gabarit (NCC) capture la forme globale et reçoit le poids principal ; le HOG apporte une information de texture/orientation complémentaire ; les moments de Hu, plus instables sur des tracés fins, ne jouent qu'un rôle d'appoint. Chaque étudiant possédant plusieurs signatures de référence, on agrège par le **maximum** (la signature de référence la plus proche), puis on identifie l'étudiant le plus probable, accepté au-delà d'un seuil τ_{sig} :

$$S(id) = \max_{\rho \in \text{Ref}(id)} s(q, \rho), \quad \hat{i} = \arg \max_{id} S(id), \quad S(\hat{i}) \geq \tau_{sig}$$

L'identifiant ainsi déduit de la signature (*studentID_signature*) est confronté à celui lu sur la grille (*studentID_grid*). L'égalité confirme la présence ; une signature non reconnue laisse la colonne vide ; deux identifiants différents signalent une possible **usurpation**, que le professeur devra vérifier. La Figure 6 montre la normalisation et le descripteur HOG d'une signature correctement identifiée.

Authentification de signature - normalisation et descripteurs




Figure 6 — Authentification de signature : sous-image extraite, normalisation 192x96 (cadre retiré, recentrage par centre de masse) et descripteur HOG. L'identité est confirmée par score combiné.

3.5. Reconnaissance du texte manuscrit (réseaux de neurones)

Le formulaire est rempli en majuscules, un caractère par case. La reconnaissance des lettres (prénom, nom) et des chiffres (mantisse, exposant) est donc un problème de **classification de caractères isolés**, traité par deux réseaux de neurones convolutifs partageant la **même architecture** (Figure 7), seule la tête de classification différant : 26 classes (A–Z) pour les lettres, 10 classes (0–9) pour les chiffres. Mutualiser l'architecture simplifie la maintenance et n'exige qu'un seul schéma à décrire.

Architecture commune des CNN de reconnaissance de caractères (K=26 lettres · K=10 chiffres)



Optimiseur Adam · entropie croisée · EMNIST (train/val/test) · affinage lettres par apprentissage par transfert (augmentation affine)

Figure 7 — Architecture commune des CNN de reconnaissance de caractères (entrée 28x28, deux blocs convolutifs, classifieur dense). K = 26 pour les lettres, K = 10 pour les chiffres.

Le réseau enchaîne deux blocs convolutifs (deux convolutions 3x3 suivies d'un sous-échantillonnage 2x2) faisant passer la résolution de 28x28 à 7x7 avec 64 canaux, puis un classifieur dense (128 neurones, ReLU, abandon de 0,3) et une couche de sortie à K classes. Cette taille modeste est **délibérée** : le problème (caractères isolés, 28x28) est proche de MNIST, pour lequel des réseaux de cette envergure atteignent déjà d'excellentes performances ; un réseau plus profond surajusterait sur notre faible volume de données réelles. La probabilité de la classe k est donnée par la fonction softmax sur les logits z, et la prédiction est la classe la plus probable :

$$p_k = \frac{e^{z_k}}{\sum_j e^{z_j}}, \quad \hat{y} = \arg \max_k p_k$$

Apprentissage. Chaque réseau est entraîné sur la base EMNIST (variante *letters* pour 26 classes, *digits* pour 10 classes), en respectant la **méthodologie imposée** de séparation en trois bases distinctes : une base d'apprentissage, une base de **validation** (pour le suivi de la généralisation et la sauvegarde du meilleur modèle) et une base de **test** indépendante pour l'évaluation finale. L'optimisation minimise l'entropie croisée par l'algorithme Adam (taux d'apprentissage 10^{-3}) :

$$\mathcal{L} = - \sum_k y_k \log p_k$$

Affinage sur les données du projet (lettres). Pour réduire l'écart de domaine entre EMNIST et l'écriture réelle des formulaires, le réseau de lettres est **affiné par apprentissage par transfert** sur un jeu construit à partir des vérités terrain : les prénoms et noms étant connus, on apparie chaque case non vide à sa lettre lorsque le nombre de cases coïncide avec celui des lettres du nom. On obtient 1 105 lettres issues de 221 formulaires. L'apprentissage utilise une **augmentation de données** par transformations affines aléatoires (rotation $\pm 10^\circ$, translation ± 2 px), un taux d'apprentissage réduit ($3 \cdot 10^{-4}$) et 25 époques.

Segmentation amont (bas niveau). En amont du réseau, l'isolement des caractères reste de bas niveau : analyse de composantes connexes, une composante étant retenue comme chiffre si sa hauteur est proche de la plus grande composante de la case ; le séparateur décimal est identifié comme une composante petite, étroite et située dans la moitié basse de la case (un point se pose sur la ligne de base). Une **garde de « case vide »** (taux d'encre, hors cadre, inférieur à 1 %) empêche le réseau de produire des chiffres parasites dans une case non renseignée — correctif déterminant pour éviter qu'un exposant absent ne soit « halluciné ». La Figure 8 illustre cette segmentation et les imagerie 28x28 produites en entrée du CNN.




Figure 8 — Segmentation bas niveau des chiffres d'une mantisse manuscrite (« 3,75 ») : binarisation, composantes connexes, puis normalisation de chaque chiffre isolé au format EMNIST 28x28 fourni au CNN.

3.6. Reconnaissance du texte imprimé

Les champs imprimés de la première page (module, professeur, date, code, notes maximale et de validation) sont lus par reconnaissance optique de caractères (**easyOCR**), méthode de haut niveau autorisée pour le texte. Les ROIs concernées sont agrandies et leur contraste renforcé (CLAHE) avant reconnaissance. Une stratégie **double source** lit la date et le code à la fois dans la bande colorée « CODES EXAM » et dans l'en-tête supérieur, en privilégiant la source la plus fiable pour chaque champ, ce qui corrige les confusions fréquentes (O/0, séparateurs de date).

3.7. Paramètres du système

Conformément au critère de qualité de programmation (§8), les paramètres de réglage sont **centralisés** (et non codés en dur de façon dispersée), afin d'être ajustés et justifiés aisément. Les principaux sont rassemblés dans le Tableau 1.

Étape	Paramètre	Valeur
Recalage photo (ORB)	ratio de Lowe / seuil RANSAC	0,75 / 5 px
Repère canonique	dimensions (W × H)	900 × 1270
Rendu PDF	résolution	150 ppp
Lecture de grille	seuil d'acceptation du pic p	0,04
Cases à cocher	seuil d'encre τ_{encre} / plein	0,10 / 0,30
Motif en croix	seuil diagonal τ_{diag}	0,12
Cryptogramme	seuil NCC / majorité	0,50 / 50 %
Signature	poids (NCC, HOG, Hu)	0,60 / 0,35 / 0,05
CNN	optimiseur / taux d'apprentissage	Adam / 10^{-3}
CNN (affinage lettres)	taux / époques / augmentation	$3 \cdot 10^{-4}$ / 25 / affine

Tableau 1 — Principaux paramètres du système, centralisés dans `utils/config.py`.

4. Protocole expérimental

Bases d'apprentissage. Les CNN sont mis au point sur EMNIST en respectant la séparation apprentissage / validation / test. Les hyper-paramètres (nombre d'époques, sauvegarde du meilleur modèle) sont choisis sur la base de **validation** ; la base de **test**, jamais vue à l'apprentissage, mesure la capacité de généralisation. L'affinage des lettres utilise un jeu annoté à partir des vérités terrain du projet, lui-même scindé apprentissage / validation.

Évaluation système. La base fournie (FORM1, FORM2, FORM3) contient les vérités terrain au format tableur. On compare, cellule par cellule, les fichiers produits par le pipeline aux fichiers de référence. La comparaison est rendue **robuste aux formats** : les dates sont uniformisées, les nombres écrits en texte sont comparés numériquement (« 2.3 » et 2,3 sont jugés égaux) et le préfixe « G » du code de groupe est neutralisé. Les résultats sont agrégés selon les quatre axes du challenge. Le temps d'exécution est également mesuré (≈ 900 s pour 43 formulaires). Évaluer en parallèle sur trois formulaires distincts (FORM1/2/3) fournit une estimation de la **généralisation** à des mises en page voisines mais non identiques. L'exactitude d'un axe est la proportion de cellules correctement lues parmi les cellules évaluées :

$$\text{Exactitude}(\text{axe}) = \frac{N_{\text{corrects}}}{N_{\text{evalues}}}$$

5. Résultats expérimentaux et discussion

Le Tableau 2 présente l'exactitude par axe sur le formulaire FORM1 (43 formulaires PDF, 1 644 cellules évaluées). Le Tableau 3 détaille la lecture du Student ID et l'authentification de signature sur les trois formulaires, et le Tableau 4 les performances des réseaux de caractères.

Axe (FORM1)	Cellules	Exactitude
Lecture de l'imprimé	519 / 621	83,6 %
Lecture du graphique	432 / 702	61,5 %
Authentification des signatures	24 / 41	58,5 %
Lecture du manuscrit	64 / 280	22,9 %
Global	1039 / 1644	63,2 %

Tableau 2 — Exactitude par cellule, par axe du challenge, sur FORM1.

Sous-base	n	Student ID	Signature	Non reconnue
FORM1 — photos	32	84,4 %	62,5 %	15,6 %
FORM1 — PDF	43	97,7 %	58,1 %	16,3 %
FORM2 — photos	22	90,9 %	50,0 %	18,2 %
FORM2 — PDF	50	92,0 %	58,0 %	12,0 %
FORM3 — photos	41	87,8 %	63,4 %	12,2 %
FORM3 — PDF	46	100 %	60,9 %	8,7 %

Tableau 3 — Lecture du Student ID (grille) et authentification de signature sur les trois formulaires (résultats reproduits par eval/evaluate.py).

Modèle / mesure	Base	Résultat
CNN chiffres — exactitude	test EMNIST	99,56 %
CNN lettres (affiné) — exactitude	validation (réel)	65,76 %

Tableau 4 — Performances des réseaux de reconnaissance de caractères.

Le réseau n'est pas le maillon faible du manuscrit. Le CNN de chiffres atteint 99,56 % sur EMNIST, alors que la lecture manuscrite des formulaires plafonne à 22,9 %. L'écart s'explique non par le classifieur mais par la **chaîne autour** du réseau (segmentation des cases, détection du séparateur décimal, gestion des cases vides) et par l'écart de domaine entre EMNIST et l'écriture réelle. Les correctifs apportés — détection du point décimal par sa position basse, garde anti-parasite sur les cases vides, filtrage des fragments de cadre — ont fait progresser cet axe (de 18,8 % à 22,9 %). Il reste néanmoins l'axe le plus difficile, ce qui est conforme à la littérature : la reconnaissance d'écriture libre, sur peu de données annotées et déséquilibrées, est intrinsèquement ardue.

Le seuil de détection des cases n'influence pas le résultat. Un balayage systématique du seuil d'encre des cases à cocher sur l'intervalle [0,08 ; 0,30] laisse l'exactitude des choix multiples strictement inchangée (≈ 59 %). Ce résultat négatif, important, indique que les erreurs ne proviennent pas de la sensibilité d'encre mais de la **localisation** des cases ; il oriente les travaux futurs vers l'amélioration de la segmentation des cases plutôt que vers le réglage du seuil. C'est précisément le type d'analyse que permet une démarche expérimentale rigoureuse.

Une erreur dans la vérité terrain fournie. L'examen détaillé des écarts a révélé que, pour le champ « Module », le formulaire imprime « IG.1103 », valeur que le système lit correctement, alors que la vérité terrain indique « IG.2405 » (le numéro du module du projet, et non celui imprimé sur la copie). Ce champ, identique pour tous les formulaires, pénalise donc à tort une quarantaine de cellules. En corrigeant cette incohérence, l'exactitude globale réelle se situe plutôt autour de **65 %**. Cette observation illustre l'importance d'un regard critique sur les données d'évaluation elles-mêmes.

Généralisation entre formulaires. Le Tableau 3 montre que la lecture du Student ID sur grille est **très robuste** (84 à 100 %), y compris sur des photos prises à main levée, ce qui valide le recalage par

homographie et la lecture par *arg max*. Les PDF, plus propres, atteignent 92 à 100 %. L'authentification de signature est plus modeste (50 à 63 %), limitée par la qualité variable des photos et la ressemblance de certaines signatures ; le système distingue toutefois correctement présence, non-reconnaissance et divergence d'identité, ce qui est l'objectif opérationnel (lever des alertes pour vérification humaine).

Coût et robustesse. Le pipeline complet s'exécute **sans aucune correction manuelle et sans plantage** sur l'ensemble des formulaires, conformément à la condition d'éligibilité au challenge ; nous avons reproduit les mesures de lecture des grilles et des signatures à l'identique. Le temps de traitement (~900 s pour 43 formulaires) est dominé par le rendu des PDF et l'inférence des réseaux, et reste compatible avec un usage par lot.

6. Conclusion et perspectives

Nous avons conçu et mis en œuvre un système complet de vision par ordinateur répondant au cahier des charges de DeepForm : validation des présences et lecture automatisée de formulaires d'examens semi-structurés. L'architecture est modulaire et conforme aux spécifications (programme principal, deux programmes et leurs sous-fonctions, formats de fichiers imposés). Les contraintes méthodologiques sont respectées : les éléments graphiques sont traités **exclusivement** par des méthodes de bas niveau (seuillage, morphologie, Hough, composantes connexes, corrélation normalisée), tandis que les textes sont confiés à des méthodes de plus haut niveau (OCR pour l'imprimé, CNN pour le manuscrit) dont les architectures et les paramètres sont justifiés et documentés.

Sur le plan expérimental, le système atteint une exactitude globale de l'ordre de **63 à 65 %**, avec des performances solides sur l'imprimé et la lecture des grilles, et plus modestes sur le manuscrit — l'axe intrinsèquement le plus difficile. L'étude a également mis en évidence, par une démarche d'analyse critique, deux faits saillants : l'invariance des résultats au seuil de détection des cases, et une erreur dans la vérité terrain fournie. Plusieurs perspectives concrètes se dégagent :

- **Affiner le CNN de chiffres** sur les chiffres réels des formulaires, comme cela a été fait pour les lettres, afin de réduire l'écart de domaine sur l'axe manuscrit.
- **Améliorer la localisation des cases MCQ** (segmentation et appariement des cases aux lettres), levier identifié comme déterminant pour l'axe graphique par le balayage de seuil.
- **Rééquilibrer et augmenter le jeu de lettres** (classes rares F, Q, V, X, Z) et étendre l'augmentation de données pour relever l'exactitude du manuscrit.
- **Recaler finement certaines ROIs** (champs de comptage des conditions) et gérer le signe négatif de l'exposant dans le chemin CNN.
- **Adopter une validation croisée** pour fiabiliser le choix des hyper-paramètres et estimer la variance des performances entre formulaires.

Références

- [1] R. Kasturi, L. O'Gorman, V. Govindaraju, « Document image analysis: A primer », Sadhana, 2002.
- [2] D. G. Lowe, « Distinctive Image Features from Scale-Invariant Keypoints », International Journal of Computer Vision, 2004.
- [3] E. Rublee, V. Rabaud, K. Konolige, G. Bradski, « ORB: An efficient alternative to SIFT or SURF », ICCV, 2011.
- [4] M. A. Fischler, R. C. Bolles, « Random Sample Consensus (RANSAC) », Communications of the ACM, 1981.

- [5] R. O. Duda, P. E. Hart, « Use of the Hough Transformation to Detect Lines and Curves in Pictures », Comm. of the ACM, 1972.
- [6] R. Smith, « An Overview of the Tesseract OCR Engine », ICDAR, 2007.
- [7] G. Cohen, S. Afshar, J. Tapson, A. van Schaik, « EMNIST: an extension of MNIST to handwritten letters », IJCNN, 2017.
- [8] Y. LeCun, L. Bottou, Y. Bengio, P. Haffner, « Gradient-Based Learning Applied to Document Recognition », Proceedings of the IEEE, 1998.
- [9] J. Yosinski, J. Clune, Y. Bengio, H. Lipson, « How transferable are features in deep neural networks? », NeurIPS, 2014.
- [10] N. Dalal, B. Triggs, « Histograms of Oriented Gradients for Human Detection », CVPR, 2005.
- [11] M.-K. Hu, « Visual Pattern Recognition by Moment Invariants », IRE Transactions on Information Theory, 1962.